

FastMem-RMT: быстрая память для continual associative retrieval

Адам Сулиман

May 12, 2026

Главная идея

Разделить обучение на две скорости: **быстрая память** быстро адаптируется к текущей задаче, а веса Transformer'a обновляются медленнее и меньше забывают старые ассоциации.

Мотивация проекта

- Continual learning в NLP требует адаптации к новым данным без полного переобучения модели.
- Основные риски: **catastrophic forgetting**, потеря пластичности и слабый перенос знаний между задачами.
- Мы фокусируемся не на универсальном LLM-бенчмарке, а на контролируемой задаче, где преимущество memory-архитектуры должно проявиться максимально явно.

Рабочая гипотеза

FastMem-RMT должен быть особенно полезен в задачах, где нужно быстро запоминать новые key-value ассоциации и не терять старые.

Что проверяем

- удержание старых ассоциаций;
- скорость обучения новых ассоциаций;
- устойчивость к интерференции;
- knowledge transfer между этапами.

Почему обычных задач мало

- GLUE/sentiment могут не выявить роль памяти;
- короткий контекст часто решается attention-бейзлайном;
- нужен стресс-тест именно для механизма памяти.

Ключевой вопрос

Может ли быстрая память снижать забывание без потери пластичности?

Предлагаемое решение: FastMem-RMT

Base RMT

$$M^{t+1} = f_{\theta}(M^t, x_t)$$

Память передаётся от сегмента к сегменту и несёт сжатую информацию о предыдущем контексте.

FastMem-RMT


$$M_f \leftarrow M_f - \eta_f \nabla_{M_f} \mathcal{L}$$

Память обновляется быстрым gradient step, а веса θ обновляются реже.

Две скорости адаптации

- **fast memory**: batch-level adaptation;
- **slow weights**: более стабильное обучение;
- цель: меньше забывания при сохранении пластичности.

Схема FastMem-RMT



Датасеты и метрики

Данные

- Основной эксперимент: синтетический генератор key-value ассоциаций.
- Каждый этап добавляет новый набор ассоциаций.
- Модель обучается только на текущем этапе, без replay.
- После каждого этапа модель тестируется на всех уже встреченных этапах.

Метрики

Пусть $A_{t,i}$ — ассигура на этапе i после обучения до этапа t .

$$\text{SeenAvg}(t) = \frac{1}{t+1} \sum_{i=0}^t A_{t,i}$$

$$\text{Forget}(T) = \frac{1}{T} \sum_{i=0}^{T-1} \left(\max_{k \leq T} A_{k,i} - A_{T,i} \right)$$

$$\text{BWT}(T) = \frac{1}{T} \sum_{i=0}^{T-1} (A_{T,i} - A_{i,i})$$

- максимизируем SeenAvg и BWT;
- минимизируем Forgetting.

Дополнительная проверка

Incremental CIFAR-100, где классы изображений подаются поэтапно, использовался как proof of concept механизма fast memory RMT.

Экспериментальные результаты

Модель	Final acc.	Seen avg.	Forgetting
Transformer/MHA	0.124 ± 0.086	0.039 ± 0.025	0.393 ± 0.014
Base RMT	0.796 ± 0.026	0.548 ± 0.032	0.204 ± 0.008
FastMem-RMT	0.858 ± 0.044	0.662 ± 0.088	0.183 ± 0.064

Интерпретация

FastMem-RMT выигрывает у Base RMT не просто за счёт наличия memory tokens, а за счёт отдельного fast update механизма. Это особенно заметно в seen-stage accuracy: модель лучше сохраняет доступ к уже выученным ассоциациям.

Важное ограничение

Vocab-growth MQAR оказался плохо откалиброван: часть моделей не решает даже single-stage вариант, поэтому этот benchmark мы сейчас не рассматриваем.

Выводы

- FastMem-RMT является перспективной memory-архитектурой для continual associative retrieval.
- Быстро обновляемая память снижает забывание и улучшает retention относительно Base RMT.
- Incremental CIFAR подтверждает благоразумность идеи, но остаётся вторичным в рамках данной презентации.

Планы

- расширить сравнение с replay, LoRA/O-LoRA, EWC, GEM;
- перенести лучший setup в PyContinual или аналогичный CL-фреймворк;
- проверить FastMem-RMT на более реалистичных long-context NLP задачах: RULER, BABILong, continual QA.